

INTELLIGENCE ARTIFICIELLE · 2026

# JEPA

**Joint Embedding Predictive Architecture**

*par Yann LeCun — La voie vers une IA qui comprend vraiment le monde*



# Plan

*Ce que nous allons couvrir ensemble*

01

## Introduction

Le problème fondamental de l'IA actuelle

02

## Plan

Vue d'ensemble de la présentation

03

## JEPA

Définition, architecture, how it works

04

## Apprentissage auto-supervisé

Mécanisme d'entraînement spécifique au JEPA

05

## Variantes & Applications

I-JEPA, V-JEPA, TS-JEPA et autres

06

## Avantages & Limites

Bilan honnête : forces et défis ouverts

07

## Mini Projet : MiniJEPA pour la prediction des patches masques par apprentissage supervisé

# L'IA actuelle : brillante... mais aveugle ?

## Prédire pixel par pixel

MAE, diffusion, LLM prédisent chaque détail brut. Résultat : ils apprennent du bruit, pas la structure du monde.


## Pas de modèle du monde

Les LLMs prédisent le prochain token — efficace, mais sans causalité, ni planification, ni raisonnement réel.

## La question clé

Comment apprendre des représentations abstraites et prédictives SANS supervision explicite ?

La solution proposée par Yann LeCun : le JEPA



# Qu'est-ce que le JEPA ?

**Joint Embedding Predictive Architecture** — un modèle qui prédit des **représentations abstraites**, jamais des données brutes.

**J****Joint**

Deux encodeurs partagent le même espace de représentation (embedding space) — pas de données brutes, pas de pixels.


**E****Embedding**

L'apprentissage opère dans un espace latent abstrait — compact, sémantique, robuste au bruit.

**P****Predictive**

Le predictor apprend à anticiper la représentation d'une partie masquée depuis la partie visible.

# Les 3 composants essentiels



1

## Context Encoder ( $f_\theta$ )

Reçoit les patches visibles (50–75 % de l'image). Vision Transformer entraîné avec backprop. Produit  $z_{\text{ctx}}$ .

2

## Target Encoder ( $f_{\bar{\theta}}$ )

Encode les patches masqués (cibles). MIS À JOUR via EMA uniquement — pas de rétropropagation directe. Produit  $z_{\text{tgt}}$ .

3


## Predictor ( $g_\phi$ )

Léger réseau qui prédit  $z_{\text{tgt}}$  à partir de  $z_{\text{ctx}}$  + positions des patches masqués. C'est ici que le raisonnement opère.

# Flux de données complet

Scientific Editorial

## Inside the Joint Embedding Predictive Architecture (JEPA)



L'input visible → Context Encoder →  
représentation  $z_{ctx}$  compacte



L'input cible (masqué) → Target Encoder  
→  $z_{tgt}$  (ground truth latente)




Le Predictor produit  $\hat{z}_{tgt}$ . La perte =  
 $\|\hat{z}_{tgt} - z_{tgt}\|^2$



Jamais de reconstruction pixel ! La perte  
est purement dans l'espace abstrait.

# Comment le JEPA apprend sans labels ?



## Masquage automatique

Spatial (I-JEPA) ou temporel (V-JEPA). Les paires (contexte, cible) sont générées automatiquement — zéro annotation humaine.



## Fonction de perte L2

$\min \|g_\phi(z_{ctx}) - z_{tgt}\|^2$  — similarité cosinus ou distance euclidienne dans l'espace latent.



## EMA — clé anti-effondrement

Le Target Encoder n'est JAMAIS optimisé par backprop. Ses poids = moyenne glissante du Context Encoder ( $\tau \approx 0.996$ ).

# Pseudocode d'entraînement JEPA

```
for x in dataloader:
    ctx, tgt_patches, tgt_pos = mask_strategy(x)    # masquage auto

    # — Context encoder (gradients actifs) —————
    z_ctx = context_encoder(ctx)

    # — Prédiction des représentations cibles —————
    z_pred = predictor(z_ctx, tgt_pos)

    # — Target encoder — AUCUN gradient —————
    with torch.no_grad():
        z_tgt = target_encoder(tgt_patches)

    loss = F.mse_loss(z_pred, z_tgt.detach())
    loss.backward()
    optimizer.step()

    # — Mise à jour EMA — clé pour éviter l'effondrement —
    ema_update(context_encoder, target_encoder, tau=0.996)
```



# La famille JEPA : un écosystème complet

## I-JEPA

×10 vs MAE

### Images

Classification, détection sans labels

## V-JEPA

Temporal

### Vidéo

Prédiction de mouvement, anticipation

## LeJEPA

Formel

### Théorie

Normalisation gaussienne — anti-collapse

## TS-JEPA

Temporal

### Séries

Finance, IoT, prévisions climatiques

## Signal

Médical

### EEG/Bio

BCI, diagnostic médical

## Var-JEPA

Émergent

### Hybride

Pont prédictif ↔ génératif (en cours)

I-JEPA : efficacité computationnelle ×10 vs MAE — meilleure généralisation sur ImageNet sans labels

# Bilan honnête : forces et défis ouverts

## AVANTAGES



Représentations sémantiques — ignore le bruit et les détails parasites



Robuste aux transformations anodines (rotation, bruit, compression)



Compatible nativement avec la planification et le raisonnement



Plus léger que les modèles génératifs sur données haute résolution



Apprentissage  $\times 10$  plus rapide que MAE (I-JEPA sur ImageNet)

## DÉFIS OUVERTS



Risque d'effondrement (atténué par EMA + LeJEPa normalisation gaussienne)



Espace latent abstrait — moins interprétable qu'un modèle reconstitutif



Performances dépendent fortement du masquage et de la tâche choisie




Peu testé sur données très hétérogènes (texte + image + audio combinés)

# **MiniJEPA** : Prédiction des patches masqués par apprentissage auto-supervisé

CIFAR-10 | PyTorch | CNN

## Principe :



La loss est calculée dans l'espace latent — jamais sur les pixels bruts

# Collapse Problem & EMA Solution


## Le Collapse Problem

The Collapse Problem



**COLLAPSE**

## EMA comme Solution



**Exponential Moving Average**

**Solution implémentée :** `update_ema(target_encoder, context_encoder, momentum=EMA=0.99)`


# Training Loop Optimization — Code Réel

```
optimizer.zero_grad()  
loss.backward()  
optimizer.step()  
update_ema(target_encoder, context_encoder, momentum=EMA)
```

zero\_grad → backward → step → update\_ema — cycle complet par batch

# Convergence & Reconstructions Visuelles

Courbe de Loss — 20 epochs




Loss : 0.45 → 0.22 | CIFAR-10 32x32

# Convergence & Reconstructions Visuelles

Epoch 20/20: 100%  196/196 [02:41<00:00, 1.57it/s, emb\_std=0.1041, loss=0.507]

Saved checkpoint to ./outputs/mini\_jepa\_final.pt




Le modèle capture couleur et texture des patches masqués




# Exemples des reconstructions visuelles


Original




Masked




Reconstructed



Original



Masked



Reconstructed



# Améliorations & Pistes de Recherche

## Limites

Patches reconstruits flous — résolution 32x32 de CIFAR-10 est trop basse

CNN limité vs Transformers pour capturer les dépendances globales

Masquage unique par image — pas de masques multi-blocs

## Améliorations

### ViT à la place du CNN

Meilleure représentation globale

### Images plus grandes (128x128+)

Résultats visuels plus nets

### Multi-block masking

Comme I-JEPA original

## Perspectives

### Fine-tuning supervisé

Classification sur les embeddings

### Gradio Demo

Interface interactive déployée

### Extension V-JEPA

Vers la prédiction vidéo

# À retenir

01

## Un nouveau paradigme

Le JEPA prédit des représentations, pas des données brutes. Cette rupture change fondamentalement ce qu'un modèle apprend.

02

## Un modèle du monde sémantique

Le JEPA apprend automatiquement à structurer le monde de façon abstraite — utile pour raisonner, planifier et agir.

03

## La voie vers une IA autonome

Voie prometteuse pour dépasser les LLMs et approcher une IA capable de comprendre, anticiper et décider.

*"Le JEPA ne remplace pas tout — mais il pourrait être le cœur de l'IA de demain." — Yann LeCun*